实地报告 · 2026 年 6 月

AI Auto-Research 基准全景与 SOTA

七十七个公开基准正在同时丈量 AI 在科研流水线里的能力——从想法生成到同行评审，再到论文传播。本文是这张地图：哪里已经饱和、哪里仍是前沿、什么样的系统在赢、什么样的问题还没被解决。

编者整理 · MinionsOS · 阅读时长 **约 22 分钟** · **2026-06-17**

78	14	5	2024–26
收录基准	本会话已落盘	ADAPTERS 已写	发表跨度

I

2026 春季动态

在我们汇总这份报告前的最后六十天里，整张地图被重新画过一次。

本季度的几条主线值得在进入逐项基准之前先讲清楚。第一条是 *open-weight* 阵营第一次在某个具体基准上反超闭源模型：阿里 **Tongyi DeepResearch** 30B-A3B MoE 的 Heavy 变体在 **BrowseComp** 上拿到 **69.0%**，超过了所有公开报告过分数的闭源 deep-research 系统（arXiv:2510.06135 / 2510.24701）。MoE 的算法账目同时改写了"价格-能力"曲线——总参数 30B、激活 3B，开源协议 MIT。

第二条是 **Anthropic** 把 RE-Bench 的分数在几周内拉了 60%。Claude Opus 4.6 的单次 RE-Bench（METR 设计的 4 小时 AI 研发任务）跳到 **29.8%**；4 月 16 日发布的 Opus 4.7 把 SWE-Bench Pro 从 53.4% 推到 **64.3%**；4 月 7 日的 Mythos preview 在 SWE-bench Verified 上录得 **93.9%**。OpenAI 已在 5 月 19 日的官方博客宣布 *不再把 SWE-bench Verified 当作前沿评测指标*——它正式饱和了。

第三条是 **Sakana AI Scientist v2** 的论文于 2026 年初登 *Nature* 651 期 914-919 页，这是史上第一份完全由 AI 生成、且通过真实同行评审的稿件。但同期的独立评估（Beel et al., arXiv:2502.14297）依然刺耳：v2 的实验仍有约一半失败，"新颖性判断"会把已有方法误标成新发现。一个有用的提醒是：*Nature 的章 ≠ benchmark 的 SOTA*。

第四条是 **Google DeepMind** 在 5 月 19 日 I/O 上把 AI Co-Scientist 的 *Hypothesis Generation* 接口公开给了独立研究者，姊妹系统 ERA（Empirical Research Assistance）也在同月的 *Nature* 报告 AI 写的科研代码胜过人类基线。Google 这条线的特点是不报数字、报湿实验复现。

第五条是 **AIRA-2**（Meta 系，arXiv:2603.26499，3 月）：一个进化-搜索式的 ML 研究 agent，**MLE-bench-30 在 24 小时拿到 81.5% 平均百分位、72 小时 83.1%**。这是本季度唯一一个跨越 80% 线的 auto-research 基准——所有其他研究类基准（PaperBench、RE-Bench、AutoResearchBench）仍稳稳停留在 30–40% 以下。

本季度新增的七个基准

下面这七个基准在我们之前 73 项的目录之外，发表都在 2026 年第一/第二季度，建议作为下一轮收录候选：

- **DRACO**（Perplexity × Harvard，arXiv:2602.11685）：100 个生产级研究任务、10 个领域、40 国资源、专家校准 rubric。Perplexity Max 与 Microsoft Researcher 都已采纳。Leni 报 71.6%，Perplexity 自家 70.4%。
- **AutoResearchBench**（arXiv:2604.25256）：Deep Research 与 Wide Research 双任务。本季度最严苛——Opus 4.6 / GPT-5.4 / Gemini 3.1 Pro 在它上面准确率

都 *不到 10%*。

- **AIRS-Bench**（与 AIRA-2 同源发布）：超出 MLE-bench Kaggle 范围的前沿研究工程任务。
- **DeepResearch Bench**（Ayanami0730）：22 个学科的 deep-research agent 综合评测，Microsoft 与 Z.ai 在对标材料中都使用了它。
- **AgencyBench**（GAIR-NLP，ACL 2026 主会，arXiv:2601.11044）：在 **1M token** 真实上下文下做长程自治 agent 评测，纯压力测试。
- **PRDBench**（arXiv:2510.24358）：50 个真实 Python 项目、20 个领域、结构化 PRD 需求。元趋势：基准本身也开始由 agent 自动生产。
- **LiveAgentBench**（arXiv:2603.02586）：104 个从社交媒体抓取的真实场景。

> **本季度结论**
>
> Open-weight 在某些特定能力（BrowseComp / SWE-Bench Pro 性价比）上首次超过闭源；SWE-bench Verified 正式饱和退役；前沿的真正战场转移到 SWE-Bench Pro、PaperBench、RE-Bench、HLE、AutoResearchBench 这五个基准上；研究类自治长程任务（>4 小时）仍是最难的一环。

❧

II

Memory 记忆基准

四个基准在丈量对话记忆、跨会话回忆、冲突解决——长期运行研究 agent 的"地基"。

记忆是瓶颈。一个昨天学到的事实今天就忘掉的研究 agent，无法在自己的工作上继续累积。Mem0 在 2026 年的 *State of AI Agent Memory* 报告中明确指出：今年记忆已经成为有自己专属基准套件的*一级架构组件*。三篇并行 arXiv 论文（2603.04257 Indexed Experience Memory、2605.03675 Tiered Memory Architecture、2602.22769 Long-Horizon Memory）一致把"有限上下文窗口"诊断为长程任务的核心瓶颈。一个有用的实操信号：所谓"幻觉"，多数其实是 retrieval 错过。

LOCOMO — LONG CONVERSATIONAL MEMORY

arXiv:2402.17753 · Snap Research · 2024

评测超长程对话记忆：5 个 session × 约 300 轮，跨度 30 天以上。题型覆盖单跳、多跳、时序、开放域和对抗性 QA。

SOTA： Mem0 的 token-efficient memory algorithm 综合分 **92.5**（在 LongMemEval 上 94.4），单次查询约 6,900 tokens。LiCoMemory 在时序推理上 +29.6 分、多跳推理 +23.1 分。

赢家配方： RAG-based 系统（Mem0、MemoryBank）+ 选择性抽取 + 实体链接 + 时序推理 + 记忆衰减。Full-context 基线动辄 100K tokens 一次查询。

MEMBENCH — 多任务 AGENT 记忆

arXiv:2506.21605 · ACL 2025 Findings

多任务 agent 记忆基准，覆盖 simple / conditional / highlevel / highlevel-rec 四个难度，并设有 *Make Noise* 污染条件以测鲁棒性。角色 thread 与事件 thread 分离评估。

SOTA： 截至 2026-Q1 没有公认的 SOTA。论文在 GPT-4 / Claude 等多模型上做了基线对比，但全文聚焦于框架设计而非排行榜竞争。

赢家配方： 强调"有效性 / 效率 / 容量"三维评测，专测对抗噪声下的稳定性。

MEMORYAGENTBENCH — 四能力轴评测

arXiv:2507.05257 · ICLR 2026 · 2025

评测四种核心记忆能力：精确检索、test-time learning、长程理解、冲突解决。把长上下文数据集改写为增量多轮交互。

SOTA：没有公认 SOTA。论文在 full-context、RAG 与多个记忆框架（Letta、Mem0、A-MEM、Cognee）上跑了基线，但定位为*诊断工具*而非排行榜。

赢家配方：146 行覆盖四个能力切片。设计目的是*暴露*当前记忆系统的弱点而非给它们排序。

MEMORYARENA

归属未确认 · 2026

无法独立确认它作为标准 benchmark 的身份。检索结果指向 arXiv:2602.16313 *Benchmarking Agent Memory in Interdependent Multi-Session Agentic Tasks*，但该论文并未使用 "MemoryArena" 这个名字。

SOTA：若 arXiv:2602.16313 即是它的本体，则该工作聚焦于"*多 session 间彼此依赖、agent 必须把经验蒸馏成记忆并跨 session 应用*"。无公开排行榜或 SOTA 数字。

赢家配方：用显式任务依赖测试记忆，不走 QA 形式。

观察

LoCoMo 是当前唯一有清晰 SOTA 的记忆基准（Mem0 92.5），其驱动力是 token-efficient 算法。MemBench 与 MemoryAgentBench 是诊断框架，无活跃排行榜。本季度的元趋势是：cost-efficiency（每次查询多少 token）已经被列为*正式 SOTA 评分轴*。

❧

III

Idea Generation 想法生成

六个基准衡量科学创造力——从最小上下文 ideation 到 idea→experiment 闭环。

"AI 能不能生成一个值得做的研究想法"——这一问的答案，有两个让人警醒的发现。一是 **HindSight** 表明 LLM-as-Judge 与论文真实引用影响力之间是*负相关*（$\rho = -0.29$）：评委模型对"好想法"的判断和真实学术影响力背离。二是 retrieval-augmented 的单 LLM 系统能让 idea 质量提升 2.5×（$p < 0.001$）——上下文比模型更重要。

AI-IDEA-BENCH-2025 已落盘

arXiv:2504.14191 · 2025

测量 LLM 生成的研究 idea 与从 3,495 篇论文中得到的 ground-truth 后续论文之间的对齐度。双指标：与真实后续工作的对齐 + 一般参照判断。

SOTA：暂无公开排行榜；基线包括 GPT-4、Claude，按"是否预测出真实发表的后续工作"评分。

本地：345 MB · test.parquet（3,495 行）+ target_paper_data.json（23 MB find_cite + summary）+ repo 评分脚本
`outline/datasets/1.1-idea-generation/AI-Idea-Bench-2025/{data,repo}/`
*注：*31 GB 原始 PDF 全文 ZIP *已按用户要求跳过*——元数据已足够跑评测

赢家配方：单 LLM 系统（无 agent 编排）。

HEUREKABENCH

arXiv:2601.01678 · ICLR 2026

端到端科学共研 agent（co-scientist）评测，落地在真实代码仓库支持的单细胞生物学探索性问题上。考核 idea→experiment 闭环。

SOTA：无公开排行榜；基线显示 open-source LLM agent 加上 critic 模块后能再提 ~22%，缩小与闭源系统差距。

赢家配方：带 critic 模块的多 agent 系统。

HINDSIGHT

arXiv:2603.15164 · 2026

"Oracle"式评测：用真实未来论文的引用影响力 + 会议接收来反向打分生成的 idea。

SOTA：无排行榜；关键发现——retrieval-augmented 系统产出的 idea 评分高 **2.5×**（p<0.001）；LLM-as-Judge 与真实影响力呈*负相关*（ρ = −0.29）。

赢家配方：带检索的单 LLM 系统。

IDEABENCH 已落盘

arXiv:2411.02429 · KDD 2025

用高影响论文的 title/abstract + 引用集，测 LLM 在最少上下文下的研究 idea 能力。两阶段评分：GPT-4o 先按新颖性 / 可行性给排序，再算"Insight Score"相对排名。

SOTA：暂无公开排行榜；基线为 GPT-4o、Claude 等前沿 LLM。

本地：141 MB · kdm-daiict/Ideabench HF 仓库（8 文件）
`outline/datasets/1.1-idea-generation/IdeaBench/data/`
*注：*该 HF 仓库描述较简，建议跑评测前与 KDD'25 paper 中的数据集定义对照确认

赢家配方：把单 LLM 配置成"领域研究者画像"。

LIVEIDEABENCH 已落盘

arXiv:2412.17596 · 2024

从单个关键词出发的*发散性思维*评测，覆盖 22 个领域、1,180 个关键词。

SOTA： QwQ-32B-preview 的创造性表现 *已可与 claude-3.7-sonnet:thinking 持平*，尽管二者在通用智力上有差距。LLM 评委组打分轴：原创性 / 可行性 / 流畅度 / 灵活度 / 清晰度。

本地： 1.1 GB · v2 release（2025-03-29）+ repo 代码
`outline/datasets/1.1-idea-generation/LiveIdeaBench/{data-v2,repo}/`

赢家配方： 面向推理优化的 open-weight 模型可与顶级闭源持平。

RESEARCHBENCH

arXiv:2503.21248 · ACL 2026 Findings

评测 inspiration retrieval、hypothesis composition、hypothesis ranking 三个能力，全部用 2024+ 论文（无污染）。论文发现 LLM 在 *inspiration retrieval*（OOD 任务）上表现尤其出色，暗示存在新颖知识关联能力。

SOTA： 无公开 SOTA；自动抽取流程支持基准持续更新。

赢家配方： 单 LLM 系统。

多模态对照（非科研创意）

IDEA-BENCH (ALI-VILAB) 已落盘

arXiv:2412.11767 · 2024 · ali-vilab

区别于KDD'25 IdeaBench——这条线是专业级图像生成评测，覆盖 100+ 个设计任务（3d 效果、动物属性编辑、image blending、灯光编辑、movie shots、multi-view、image undo、包装渲染等）。

SOTA：论文中横向对比 GPT-4o、Gemini-Imagen、Midjourney、FLUX、Imagen-3。

本地：329 MB · 724 文件，本次会话作为多模态创意基线对照拉取
`outline/datasets/1.1-idea-generation/IDEA-Bench-ali-vilab/data/dataset/`
*注：*MinionsOS 当前没有图像生成 deliverable，所以这个 benchmark 仅作交叉对照。

观察

Idea generation 这个赛道呈现一个有反讽意味的格局：retrieval-augmented 单模型 > 多 agent 编排，open-weight 推理模型已经可与闭源顶级模型在创造力维度持平，而 LLM-as-Judge 这个曾经的"廉价裁判"被证明与真实学术影响力*反向*。

❧

IV

Literature Review 文献综述

七个原始基准 + 本季度新增的 DRACO 与 DeepResearch Bench——但这条赛道至今没有任何饱和。

没有任何文献综述类基准被解决。几个标志性数字摆在一起就能看出来：DeepScholar-Bench 的几何平均分上限是 31%，SciNetBench 的关系感知准确率不到 20%，连 CiteME 这种"给我一段文字、我告诉你引用的是哪篇论文"的简单任务，最佳 agent（CiteAgent，35.3%）和人类基线（69.7%）之间也还有 34 分差距。本季度把这条线推到聚光灯下的，是 Perplexity × Harvard 的 **DRACO** 与 Ayanami0730 的 **DeepResearch Bench**——两者都已被 Microsoft Researcher 与 Z.ai 当作对标坐标。

CITEME — 引用归属

arXiv:2407.12861 · 2024

给一段引用别人工作的文字，识别它指向哪篇论文。测的是 citation hallucination rate。

SOTA： CiteAgent（GPT-4o + 搜索/阅读工具）**35.3% 准确率**。人类基线 69.7%；前沿 LLM 单跑 4.2–18.5%。

赢家配方： 带搜索 + 阅读工具的自治 agent，比纯 LLM 高一个数量级。

DEEPSCHOLAR-BENCH

arXiv:2508.20033 · 2025

"*活体*"研究综合基准：用最近的 arXiv 论文反向生成相关工作章节。评测维度：知识合成、检索质量、可验证性。

SOTA： 没有任何系统跨过**几何平均 31%** 这条线——远未饱和。基线包括 OpenAI Deep Research、open-source 系统、各类搜索 agent。

赢家配方： 多步 deep-research agent，但这个基准本身仍是开放挑战。

IDRBENCH — 交互式深度研究

arXiv:2601.06676 · 2026

带"按需用户反馈"的 deep research：测交互的好处（质量、对齐）与代价（轮数、token 成本）。

SOTA： 关键发现——*交互对质量与鲁棒性的提升一致性强、且经常压过模型规模带来的差异*。在 7 个 SOTA LLM 上做了对比。

赢家配方： 带 user-in-the-loop 的多 agent 框架。

LITSEARCH

arXiv:2407.18940 · EMNLP 2024 · Princeton-NLP

597 个真实 ML / NLP 检索 query。指标：Recall@k + MRR。

SOTA： Dense retriever + LLM rerank 比 BM25 在 recall@5 上 **+24.8%**，rerank 再 +4.4%。商用搜索引擎落后最佳 dense retriever 多达 32 个 recall 点。

赢家配方： 密集检索 + LLM 重排序。

REPORTBENCH

arXiv:2508.15804 · ByteDance · 2025

用已发表的 arXiv 综述当 gold standard，评测 deep research agent 在学术综述生成上的能力。考核被引文献质量与陈述忠实度。

SOTA： 没有公开的具体 SOTA 分数；评测过商用 deep-research 系统。

赢家配方： 多步 deep-research agent。

SCHOLARGYM

arXiv:2601.21654 · 2026

把 deep research 的"信息收集"阶段单独切出来，2,536 个专家标注 query 跑在 570K 篇论文上。三段式评测：Query Planning、Tool Invocation、Relevance Assessment。

SOTA： 迭代式 query 分解相对单 query 检索带来 **2.9–3.3× F1** 提升。Query Planning + Relevance Assessment 是*双重瓶颈*，把 proprietary 与 open-source 的能力差异主要体现在这里。

赢家配方：多步迭代 agent。

SCINETBENCH — 关系感知检索

arXiv:2601.03260 · 2026

在 18M AI 论文上做关系感知检索：自我中心、成对、路径式三类关系理解。指标 graph F1。

SOTA：当前 retrieval agent 在关系感知任务上准确率 **< 20%**。把关系 ground-truth 显式提供后，综述质量再 +23.4%。

赢家配方：关系感知 retrieval 系统是必需的，但当前没有任何系统做到。

本季度新增（建议收录）

DRACO — DEEP RESEARCH AT-SCALE

arXiv:2602.11685 · Perplexity × Harvard · 2026

100 个生产级研究任务、覆盖 10 个领域、信息源跨 40 国，专家 rubric 校准。Perplexity Max 的 deep-research 上线即采用，Microsoft Researcher 也已对接。

SOTA：Leni **71.6%**，Perplexity 自家 70.4%。

赢家配方：带显式 rubric 的 production-grade deep-research agent。

DEEPRESEARCH BENCH

github.com/Ayanami0730/deep_research_bench · 2026

22 个独立学科的 deep-research agent 综合评测框架，目前已被 Microsoft 与 Z.ai 在对标材料中使用。

SOTA：当前公开排行榜由 Tongyi DeepResearch、OpenAI Deep Research、Perplexity 三家轮替领先；具体排名随测评批次浮动。

赢家配方：把"deep research"当作模型类来评测，而非把它当作工作流。

观察

本季度的真正变化：deep research 已经从一种工作流，变成一个被显式区分的*模型品类*——OpenAI 直接出 `o3-deep-research` 这个独立 SKU，Perplexity / Google（Gemini for Science）/ Microsoft（Researcher）/ 阿里（Tongyi DR）/ Z.ai 都有自己挂名"deep research"的产品线。

❧

V

Coding & Experiments 编码与实验

25 个原始基准 + 本季度新增的 AIRS-Bench、AutoResearchBench、PRDBench、AgencyBench——本阶段仍是密度最高的赛道。

这是 auto-research 流水线被跟踪得最密集的一段。SWE-bench 的排行榜每周都在更新，PaperBench、RE-Bench、MLE-Bench 已是 2025–2026 各家系统报告里的"头条数字"。三个分水岭把"已饱和"的基准（SWE-bench Verified、MLAgentBench）和"前沿"基准（PaperBench、MLR-Bench、RE-Bench）分开来：任务时长、捏造（fabrication）风险、与人类的差距。

本季度最重磅的事件是 OpenAI 在 5 月 19 日宣布把 SWE-bench Verified 退出"前沿评测指标"——它正式被认为饱和了。新前沿是 SWE-Bench Pro，Anthropic Opus

4.7 在它上面拿到 64.3%。MLE-bench-30 这条线则被 Meta 系的 **AIRA-2** 推到 81.5–83.1%，是本季度*唯*一跨过 80% 线的研究类基准。

软件工程

SWE-BENCH

arXiv:2310.06770 · ICLR 2024 · Princeton-NLP

2,294 个真实 GitHub issue 解决任务（Python 仓库）。定义了 agentic coding 评测的现代起点。

SOTA： Claude Mythos preview 在 Verified 上 **93.9%**（2026 年 4 月）。Full benchmark 顶尖模型 ~70–80%。OpenAI 已于 2026-05-19 宣布*不再把它当前沿指标*。

赢家配方： Claude 系列长期主导。Verified 子集已逼近饱和。

SWE-BENCH-PRO 已落盘

arXiv:2509.16941 · Scale AI · 2025

跨 41 个仓库、1,865 道题的*长程*软件工程基准。难度远高于 Verified——同一模型 Verified 70%+ 的，在 Pro 上常掉到 23%。

SOTA： Claude Mythos preview **77.8%**；Opus 4.7 **64.3%**（4 月 16 日发布即从 53.4% 跳升）；GPT-5.4 59.1%；GLM-5.1（open-weight）**58.4%**，与 Opus 4.6 仅差几个百分点。

本地： 95 MB · ScaleAI/SWE-bench_Pro 完整数据 + repo 评测脚本
`outline/datasets/1.3-coding-experiments/SWE-bench-Pro/{data,repo}/`

赢家配方：Claude 领跑；GLM-5.1 用 ~7% 的成本逼近闭源——这是本季度最强的"open-weight 在追"信号。

SWE-EVO 已落盘

arXiv:2512.18470 · 2025

多文件、长程的*软件演化*场景：跨版本重构。

SOTA： GPT-5.4 + OpenHands **25%**（同模型 Verified 72.8%）——演化任务上的能力鸿沟极大。

本地： 21 MB · 48 跨版本演化任务（仅核心 hf_jsonl + arrow，跳过 35K 文件的 trajectory dump）
`outline/datasets/1.3-coding-experiments/SWE-EVO/data/test.jsonl`

赢家配方：过新尚无密集排行榜；GPT-5 系列在测。

SUPER

arXiv:2409.07440 · EMNLP 2024 · AI2

从 ML / NLP 研究仓库设置环境并执行任务。考的是依赖解析、环境搭建、端到端执行。

SOTA： GPT-4o 端到端专家任务 **8.7%**，子任务 16.3%。

赢家配方：极难；从仓库做"复现"仍是开放问题。

科学计算编码

SCICODE

arXiv:2407.13168 · 2024

科学家手工标注，338 个子题跨 16 个学科。

SOTA： Gemini 3.1 Pro **59.0%**。11 模型平均 42.9%。

赢家配方： Google Gemini 在科学计算任务上领先。

SCIREPLICATE-BENCH

arXiv:2504.00255 · 2025

从论文出发的 agent 驱动算法复现。

SOTA： 最佳 LLM + Sci-Reproducer agent **39%** 执行准确率。

赢家配方： 带"论文阅读 + 工具使用"的 agentic 复现框架。

SCIENCEAGENTBENCH

arXiv:2410.05080 · ICLR 2025

102 个数据驱动的科学分析任务，源自 44 篇 peer-reviewed 论文。

SOTA： 最佳 agent 独立成功率 **32.4%**（带专家知识 34.3%）；o1 直接 prompt 表现接近。

赢家配方： GPT-4 / o1 级模型在测；排行榜活动有限。

CORE-BENCH

arXiv:2409.11363 · 2024

计算可复现性：跑公开发表的研究代码并回答关于其输出的问题。

SOTA： 最佳 agent 在最难任务上 **21%**。

赢家配方： 常规科学任务自动化空间巨大。

RESEARCHCODEBENCH

arXiv:2506.02314 · 2025

从 2024–2025 顶会论文派生 212 道题，测新颖 ML 研究代码实现。

SOTA： Gemini-2.5-Pro-Preview **37.3%**。即便最好的模型也解不到 40%。

赢家配方： Google Gemini 领先；前沿研究代码翻译仍是难题。

GPU kernel 与数据分析

KERNELBENCH

arXiv:2502.10517 · ScalingIntelligence · 2025

PyTorch workload 的 GPU kernel 生成。考核相对参考实现的 speedup。

SOTA： 前沿推理模型只能*追平* PyTorch 基线，没有实质性超越——典型 ~1.0× speedup。

赢家配方： GPT-5 / Claude Opus 4.x 在测；性能优化仍是未解决问题。

TRITONBENCH

arXiv:2502.14752 · thunlp · 2025

Triton GPU kernel 生成基准。

SOTA： AMD GEAK agent 在 ROCm 集 **63.3%** 执行准确率，TritonBench-modified 上 54.9%。直接 LLM prompt 仅 ~15%。

赢家配方： 专精 agent 比通用前沿 LLM 高 4 倍。

INFIAGENT-DABENCH

arXiv:2401.05507 · ICML 2024

从 CSV 文件出发的数据分析任务，257 题。

SOTA： DAAgent 专精系统：GPT-3.5 基线 +3.9%。在 34 个 LLM 上做了基线。

赢家配方： GPT-3.5 / 4 时代的结果；测的是多步数据分析工作流。

ML 研究 agent

MLAGENTBENCH

arXiv:2310.03302 · ICML 2024 · snap-stanford

13 个 Kaggle 风格 ML 实验任务。

SOTA： GPT-4 agent 平均成功率 **37.5%**；Claude v3 Opus 同为 37.5%。后续工作报告 GPT-4o + 迭代 refinement 可达 76.47%。

赢家配方： GPT-4 / Claude Opus 旗鼓相当；迭代 refinement 是关键。

MLE-BENCH

arXiv:2410.07095 · OpenAI · 2024

75 场 Kaggle 比赛，agent 必须做到奖牌级表现。

SOTA：MLE-STAR（Google，arXiv:2506.15692）在 MLE-Bench Lite 上 **64% 奖牌率**；本季度发布的 **AIRA-2**（Meta 系，arXiv:2603.26499）在 MLE-bench-30 上 *24h 81.5% / 72h 83.1%*，是本季度*唯*一跨过 80% 线的研究类基准；早期数据：o1-preview + AIDE 16.9% bronze+ 全集；R&D-Agent（Microsoft）35.1% any-medal。

赢家配方：搜索式 refinement + 集成策略。AIRA-2 用进化搜索把它推到了一个新台阶。

MLR-BENCH

arXiv:2505.19955 · 2025

开放式 ML 研究：ideation、coding、experimentation、writing 全链路。

SOTA：没有清晰 SOTA。论文最刺眼的发现：**80% 的 agent 实验结果是*捏造*的**。

赢家配方：LLM 在 ideation / writing 上能干，但执行可靠性极低。

MLGYM

arXiv:2502.14499 · Meta · 2025

RL-based AI 研究任务 gym。

SOTA：无公开 SOTA；论文报告前沿模型靠超参搜索能改进基线，但不会生成新颖假设或新架构。

赢家配方：超参搜索胜过算法创新。

PAPERBENCH — 复现 ICML 论文 已落盘

arXiv:2504.01848 · OpenAI Preparedness · 2025

从零复现 20 篇 ICML 2024 论文，8,316 个 rubric 叶节点。

SOTA： Claude 3.5 Sonnet (New) 平均复现分 **21.0%**。人类仍领先。

本地： 1.0 GB · 含 524 MB LFS-hydrated 论文复现数据（已用 git lfs fetch --include 定向拉取，参见 DOWNLOAD_STATUS.md）
`outline/datasets/1.3-coding-experiments/PaperBench/repo/project/paperbench/data/`

赢家配方： Scaffolding + 长程规划。这是 full-pipeline auto-research 的金标准。

RE-BENCH — AI VS 人类研究员

arXiv:2411.15114 · METR · 2024

METR 设计的 4 小时 AI R&D 任务，对照人类 ML 工程师。

SOTA： 2026 年初前沿模型的*50% 时间预算*下 horizon 估计为 **≥16 小时**（95% CI 8.5–55h）。Claude Opus 4.6 单次 RE-Bench **29.8%**——Anthropic 在几周内把这个分数推高了 60%。

赢家配方： 长程能力 + 工具使用。人类仍显著更快。

EXP-BENCH

arXiv:2505.24785 · Curie · 2025

从 AI 论文出发做端到端实验设计。

SOTA： 未声明赢家；论文在 GPT-4 / Claude 等模型上做了对比。

赢家配方： Agent 在*假设构造*与*结果分析*两端都吃力。

POSTTRAINBENCH

归属未确认 · 2026

LLM agent 自动化 LLM 后训练。arXiv:2603.08640 在 2026-Q1 公开网络上无可信命中。

SOTA： 未找到与该 ID 匹配的基准；可能是笔误或尚未发布。

赢家配方： 若它落地，预计测的是训练 loop 自动化。

科学发现

DISCOVERYBENCH

arXiv:2407.01725 · AI2 · 2024

从数据集驱动的假设发现。

SOTA： 最佳系统在多类 LLM 推理框架下 **~25%**。

赢家配方： 多步假设搜索 + 验证仍困难；retrieval + reasoning 组合获胜。

DISCOVERYWORLD

arXiv:2406.06769 · AI2 · 2024

虚拟环境下的 120 个科学发现任务，跨 8 个主题、3 个难度。

SOTA： 最佳系统在最难任务上 **~20% 完成率**。

赢家配方： 长程规划 + 工具使用。

FRONTIERSCIENCE

arXiv:2601.21165 · 2026

专家级科学推理，含 Olympiad 与 Research 两个子集。

SOTA：GPT-5.2 在 Olympiad 上 **77%**，在 Research 上 **25%**（首轮评测）。Olympiad 接近饱和；Research 仍极难。

赢家配方：深度推理胜过记忆。

ASTABENCH

arXiv:2510.21652 · AI2 · 2025

科学研究 agent 套件，多任务聚合分。

SOTA：未找到外部结果；论文 ID 可能不准或尚未被检索引擎索引。

赢家配方：无法确认排行榜活跃度。

RESEARCHCLAWBENCH

arXiv:2512.16969 · InternScience · 2025

科学家工作流对齐：从"再发现"到"新发现"。

SOTA：在 deep research 上 exact match **10–20%**，即便有 step-level 对齐。Idea 缺可行性，代码能跑但结果不准。

赢家配方：工作流对齐 + 执行可靠性。

LAB-BENCH

arXiv:2407.10362 · FutureHouse · 2024

超出教科书范围的生物学研究任务。

SOTA：没有公开 SOTA 数字；PaperQA 与 Aviary 系统在测，但分数未披露。

赢家配方：领域知识 + 工具使用。

本季度新增（建议收录）

AIRS-BENCH

与 AIRA-2 同源（arXiv:2603.26499） · 2026

超出 MLE-Bench Kaggle 范围的*前沿研究工程*任务。AIRA-2 把它当作互补评测轴。

AUTORESEARCHBENCH 已落盘 ADAPTER

arXiv:2604.25256 · 2026

双任务结构：Deep Research（沿目标论文做多步追踪）+ Wide Research。本季度*最严苛*的 auto-research 基准。

SOTA：Opus 4.6 / GPT-5.4 / Gemini 3.1 Pro 三个前沿模型准确率*都不到 10%*。

本地：12 MB · 1,000 题（600 deep + 400 wide）· SHA256 校验通过 · 已用 `repo/decrypt_benchmark.py` 解 obfuscation `outline/datasets/1.3-coding-experiments/AutoResearchBench/data/AutoResearchBench.jsonl` Adapter `AutoResearchBench/adapter.py`：to-jsonl（按 type 切）/ grade（deep=fuzzy title + arxiv id；wide=set F1）/ stats

赢家配方：未知——所有当前系统都失败。

PRDBENCH 已落盘 ADAPTER

arXiv:2510.24358 · 2026

50 个真实 Python 项目、20 个领域、结构化 PRD 需求。一个元趋势在它身上很显眼：基准本身也开始由 agent 自动生产。

本地：79 MB · 50 cases / 1,263 metrics（每条 0/1/2 分，max_score 2,526）· 每 case 含 PRD.md + aux 数据 + 评分 rubric + 测试 fixture
`outline/datasets/1.3-coding-experiments/PRDBench/data/data/{1..50}/`
Adapter `PRDBench/adapter.py`：to-jsonl / show / grade（LLM-judge 跑每条 metric）/ stats

AGENCYBENCH 已落盘

arXiv:2601.11044 · GAIR-NLP · ACL 2026 主会

在 **1M token** 真实上下文下的前沿自治 agent 评测，纯长程压力测试。

SOTA：闭源 48.4% vs 开源 32.1%（v2，2026 年初论文报告）。138 个任务跨 6 大能力（Backend / Frontend / Code / Game / Research / MCP），平均 ~90 tool calls / 1M tokens / 数小时执行。

本地：27 MB · v1（10 tasks）+ v2（32 scenarios / 138 tasks）
`outline/datasets/1.3-coding-experiments/AgencyBench/data/AgencyBench-{v1,v2}/`
通过 ModelScope CDN 下载（hf-mirror 走 Xet 死路）

搜索 + refinement 胜过单次生成；scaffolding 比模型规模更重要；长程任务停留在 16–20% 完成率；执行可靠性是瓶颈——MLR-Bench 的 80% 实验捏造率是这一阶段最让人不安的数字。

— 跨 25 + 4 个编码与实验基准的共性

❧

VI

Tables & Figures 表格与图

七个基准覆盖 chart QA、表格生成、科学插图、LaTeX。ChartQA 已基本被前沿 VLM 攻陷在 90%；其余仍开放。

这一阶段清晰分成两个阵营。ChartQA 这种"chart 图像 → QA"已经被前沿 vision-language model 攻陷到 90% 区间。但所有*生成*类任务（图生成、表归纳、LaTeX 生成）仍是活跃前沿——一致赢家是*多 agent + critique loop*。

ABGEN — 消融实验设计

arXiv:2507.13300 · ACL 2025

从 807 篇 NLP 论文中提取的 1,500 个专家标注样例。LLM 必须为指定模块设计消融实验并预测结果。

SOTA： 原文报告前沿 LLM 与人类专家差距巨大；并指出"*自动评测方法在该任务上不可靠*"——无干净的头条数字。

赢家配方： 前沿推理模型（GPT-4o 级）方差仍大。

ARXIVDIGESTABLES

arXiv:2410.22360 · EMNLP 2024

文献综述用表生成；arXiv 上 2,228 张表。Schema recall + cell F1 对照 gold。

SOTA： GPT-4 + retrieval 领先但绝对分极低。2025 年的后续工作 arXiv2Table 重申"*open-weight 与闭源都吃力*"。

赢家配方： 检索增强的 schema 归纳。

CHAIN-OF-TABLE

arXiv:2401.04398 · ICLR 2024 · Google

它是*方法*而非基准——把表通过原子操作链式演化出来。

SOTA： 在 WikiTableQuestions 上新 SOTA（~59–60%）、TabFact ~86%、FeTaQA。Backbone：PaLM-2 / GPT-3.5 / LLaMA-2。

赢家配方： 表分解 + 工具使用链。

CHARTQA

ACL 2022 · 9.6K 人工 + 23.1K 增广 QA

Chart 图像 QA（柱 / 线 / 饼图）。

SOTA： Claude 3.5 Sonnet **≈ 90.5%**（relaxed accuracy）。GPT-4o、Gemini 1.5 Pro、InternVL2 集中在 85–90% 区。后续 ChartQAPro（ACL'25）让同模型掉到 55.8%——*ChartQA 已基本饱和*。

赢家配方： 前沿闭源 VLM。

FIGUREBENCH

arXiv:2602.03828 · 2026

从长文本生成发表级科学插图：3,300 个文本-图对，跨多个学科。

SOTA：配套系统 AutoFigure；论文报告人评相对 GPT-4 + diffusion 基线的胜率，但无单一头条数字。

赢家配方：把任务分解成 layout + draw + critique 的 agentic 框架。

SCIFLOW-BENCH

arXiv:2602.09809 · 2026

结构感知科学示意图生成；用*逆解析*评测——渲染图像 → 解析回图结构 → 测图同构。

SOTA：极新；只有论文自带的 GPT-4o / Gemini / Imagen 系黑盒基线，全部远低于人类。

赢家配方：预期是先生成 DOT / Graphviz 再渲染的方法，但目前无公开数字。

TEXPERT

arXiv:2506.16990 · SDP 2025 @ ACL'25

多层次 LaTeX 代码生成：自然语言 → LaTeX，跨 math / tables / figures / 全章节四个难度。

SOTA：前沿闭源 LLM 在 easy 层领先，到 hard table / figure 层急剧退化。

赢家配方："compile 后再判分"是关键鉴别器。

❧

VII

Paper Writing 论文写作

三个基准衡量长篇学术写作。AutoSurvey 是事实标准；PaperOrchestra 在文献综述质量上 +50–68%。

综述生成是这一阶段最受跟踪的子任务。AutoSurvey 的四轴评测（citation recall / precision + content coverage / structure / relevance）已经成为事实标准，SurveyForge 与 AutoSurvey2 都在它的指标上做迭代。多 agent 分工 + 显式角色化是稳定赢家。

AUTOSURVEY

arXiv:2406.10252 · NeurIPS 2024

长篇综述生成，四轴评测：citation recall / precision + content coverage / structure / relevance。

SOTA：原系统 **citation recall ≈ 82.6%、precision ≈ 77.0%**，content 4.7–4.8/5（writer 用 Claude-Haiku）。SurveyForge（DeepSeek-v3）在同指标上超过它；AutoSurvey2 又改进了 coherence。

赢家配方：记忆驱动的 retrieval + 人类先验 outline。

PAPERWRITINGBENCH (PAPERORCHESTRA)

arXiv:2604.05018 · 2026

多 agent 自动 AI 论文写作，基准即论文自带的评测套件。

SOTA：PaperOrchestra 在人工 side-by-side 评测中相对自治基线**文献综述质量 +50–68%、整体论文质量 +14–38%**。

赢家配方：多 agent 显式分工。

SCIIG

arXiv:2508.14273 · 2025

论文 introduction 质量基准。

SOTA：无公开 SOTA；预期前沿闭源 LLM + related work retrieval 领先。

赢家配方：SciIG 邻近基准的共性是"retrieval + 前沿 LLM"。

观察

生成质量类基准（AbGen、ArxivDIGESTables、FigureBench、SciFlow-Bench、TeXpert、AutoSurvey、PaperWritingBench、SciIG）一致偏向多 agent + 检索增强 + critique loop 系统。绝对分离人类 gold 仍很远——这是*活跃前沿*，不是已解决的问题。

❧

VIII

Peer Review & Rebuttal 同行评审与答辩

14 个基准——评审 10 + 答辩 4。Robustness 是当前最弱前沿：prompt injection 成功率接近 100%。

评审侧测的是 grounded（基于证据）/ bias / robustness / 与人类一致性。答辩侧测的是说服策略。本季度三个发现尤其刺眼：prompt injection 在评审 LLM 上几乎百发百中；Theory-of-Mind 显式建模在答辩任务上大幅领先；而历史基准 PeerRead 上，*分数特征*对决策预测的贡献仍超过文本内容。

Peer review

AGENTREVIEW

arXiv:2406.12708 · EMNLP 2024

多 agent LLM 评审仿真，覆盖 500+ ICLR 投稿、53.8K 生成文档。

SOTA：框架本身即贡献；揭示 conformist 行为带来 27.2% 评分方差缩减。

赢家配方：把 bias / expertise / conformity 在仿真中拆开。

AI-DETECTION

arXiv:2502.19614 · 2025

"LLM 写的评审" vs "人类写的评审"识别，788,984 条样本。

SOTA：论文自家 Anchor Embedding 法 **> 60% TPR @ 低 FPR**（无公开 AUC 头条数）。

赢家配方：面向学术语域微调的上下文感知 embedding；通用检测器失效。

BREAKING-THE-REVIEWER

arXiv:2506.11113 · EMNLP 2025 Findings

对 LLM 评审者的文本对抗攻击。

SOTA：无最佳防御；多个 LLM 全线被攻破，邻接文献中自适应攻击 ASR 经常 **> 90%**。

赢家配方：针对模型的自适应攻击；静态防御脆弱。

CLAIMCHECK

arXiv:2503.21717 · EMNLP 2025

NeurIPS'23/'24 的评审 + 论文 + 专家标注 weakness↔claim 链路、validity、objectivity、type。

SOTA： GPT-4o 在三个 claim-centric 任务上做了基线；论文结论是"*显著缺陷*"——无头条 F1。

赢家配方： 把 critique 落地到具体 claim 上，而非泛指 weakness。

ICLR-2025-STUDY

Nature MI 2026 · 20K+ 评审 RCT

给人类评审者提供 LLM 反馈的随机对照实验。

SOTA：27% 的评审者更新了评审；12K+ 条建议被采纳。这*不是*"与人类一致性"排行榜。

赢家配方： 具体可执行的反馈，胜过泛泛建议；把 LLM 当"质量推手"。

PEERREAD

arXiv:1804.09635 · NAACL 2018

14K 论文 + 录用 / 拒稿决定。评审基准的历史锚点。

SOTA： 原始简单模型相对多数基线 ~21% 错误率下降。2026 年的后续工作报告 **分数特征模型 91% acc vs 文本 LLM 81%**。

赢家配方： 数值/分数特征胜过文本内容。

PROMPT-INJECTION

arXiv:2509.10248 · 2025

1K 个 LLM 生成的 ICLR'24 评审，叠加隐蔽 prompt 攻击。

SOTA：简单 injection 可达 **100% 录用分操纵**；GPT-4o-mini 分数膨胀 ~20pp。

赢家配方：混淆 + 认知过载策略；尚无可靠防御。

RATE

arXiv:2601.19637 · 2026

无标注的*评审者专长*排序：基于关键词画像 + 弱监督 embedding。

SOTA：RATE 框架；评审分配错误率 **12–30%（easy）/ 36–43%（hard）**。

赢家配方：从发表历史中得到的弱监督优于人工标注 relevance。

REVIEWAGENTS

arXiv:2503.08506 · 2025

带结构化推理迹的 ReviewBench 数据集，研究人类↔AI 评审之间的差距。

SOTA：配套 ReviewAgent 框架报告 **+6.78% 相对 AI 基线、+47.62% 相对专家评审**（actionable insights）。

赢家配方：模仿人类评审工作流的结构化 pipeline。

REVIEWMT

arXiv:2406.05688 · 2024

多轮长上下文 reviewer-author 对话。

SOTA：未找到公开 SOTA；引用的 arXiv ID 在反复检索中没有显示稳定结果。

赢家配方：无法验证。

Rebuttal 答辩

COMMITMENT-CHECKLIST

arXiv:2603.00003 · 2026

"审计作者在 rebuttal 里许下的承诺"：从答辩抽取承诺、再到终稿验证是否兑现。

SOTA：暂无 baseline 排行榜。

赢家配方：承诺识别可行，跟踪兑现仍处早期。

DRPG

arXiv:2601.18081 · ulab-uiuc · 2026

面向学术答辩的 Decompose / Retrieve / Plan / Generate 框架。

SOTA：Planner 在"哪个答辩方向最可行"上 **> 98% 准确率**，在顶会数据上显著超过基线。

赢家配方：先把质疑分解成原子问题、检索证据、再拼答辩稿。

RE²

arXiv:2505.07920 · 2025

当前最大的"评审 + rebuttal"一致性数据集：19,926 投稿、70,668 评审、53,818 答辩。

SOTA：论文给出基线 LLM 分数，但没有单一头条数。

赢家配方：一致性数据 + 多轮答辩支持。

REBUTTALAGENT

arXiv:2601.15715 · ICLR 2026

Theory-of-Mind 的 ToM-Strategy-Response 流水线（SFT + 答辩专用奖励模型 RL）。

SOTA：相对基模型 **+18.3% 平均**（自动指标）；在自动 + 人工评测上同时压过先进闭源模型。

赢家配方：显式建模"评审者心智"+ 策略性说服，胜过直接生成回复。

> *Robustness 是最弱前沿——简单攻击就能做到接近 100% 操纵，防御脆弱。Rebuttal SOTA 一致偏向"分解 → 计划 → 生成"流水线 + 领域专用 RL，不是端到端生成。*
>
> — 跨 14 个评审与答辩基准的共性

❧

IX

Paper2X 论文传播

六个基准覆盖海报、幻灯、视频、网页生成。MinionsOS 在该阶段尚无对应模块，是未来的扩展目标。

这是 auto-research 流水线最年轻的一段，六个基准全部是 2025–2026 的工作。一个稳定模式：*多 agent 分解*（内容抽取 → 布局规划 → 视觉生成）显著胜过端到端生成。MinionsOS 目前没有对应模块。

PAPER2POSTER

arXiv:2505.21497 · NeurIPS 2025

从科学论文出发的多模态海报自动生成。

SOTA： Paper2Poster 多 agent 流水线在 PaperQuiz（内容准确性）、VisualQuiz（视觉质量）、coherence 上全线压过 GPT-4o，且**少用 87% 的 token**。

赢家配方： 多 agent 分解（content extraction、layout planning、visual generation）胜过端到端。

PPTAGENT-PPTEVAL

arXiv:2501.03936 · EMNLP 2025

论文转幻灯，附 6 轴评测（content accuracy、structure、visual quality、coherence、layout、consistency）。

SOTA： PPTAgent 两阶段（reference 分析 → 通过代码动作迭代生成幻灯）在所有维度上显著超过基线。

赢家配方： 参考引导的结构抽取 + 基于代码的编辑，保证 consistency。

PAPER2VIDEO — PRESENTQUIZ

arXiv:2510.05096 · 2025

论文自动生成 ~6 分钟的演讲视频，101 对 paper-video 对。

SOTA： PaperTalker 多 agent 框架（slide generation + Tree Search Visual Choice 布局精修 + cursor grounding + 语音合成 + talking-head 渲染）在 faithfulness 与 informativeness 上压过基线。

赢家配方： 并行多模态流水线 + 视觉选择优化。

PAPER2WEB

arXiv:2510.15842 · 2025

论文转交互式网页主页生成。

SOTA： PWAgent（MCP 仓库 + 用 Docling/Marker 做多 agent 分解 + LLM）在所有评测维度上稳压模板网页与 arXiv/alphaXiv 版本，并保持**极低成本（~$0.005 / 页）**。

赢家配方： 资产分解 + agent 驱动的交互特性生成。

PRESENTEVAL

arXiv:2507.04036 · EMNLP 2025

统一的 VLM 驱动评测框架，测演讲视频的内容准确性、视觉质量、叙述 coherence 三轴。

SOTA： PresentAgent 模块化流水线（document → outline → slide generation → narration → video assembly）由 PresentEval 评测。

赢家配方： VLM 综合评分胜过单指标。

P2P

arXiv:2505.17104 · ICLR 2026

带细粒度基准的 paper-to-poster 自动生成。

SOTA： P2P 多 agent 框架（visual element processor + content generator + poster assembler，每个都带 checker 模块做迭代精修）。

赢家配方： 带专属质量检查 loop 的专精 agent 分解。

❧

X

End-to-End 通用

五个原始基准 + 本季度新增的 LiveAgentBench——HLE 仍停在 37.5%，专家级任务远未被解决。

这一类基准跨阶段——测的是系统能否在完整研究 loop 里规划、路由、执行。GAIA 与 HLE 是 2026 各家系统卡的"头条数字"。一个反复出现的模式：即便在 GAIA（450 题、3 个难度）上，也*没有任何一个模型在所有能力上都领先*。

AAAR-1.0

arXiv:2410.22394 · Lotus Labs · 2024

面向研究的任务集合（100 篇论文做实验设计 + 文献综述、rebuttal、related work）。

SOTA： Claude v3 Opus 在实验设计任务上最佳成功率 **37.5%**（MLAgentBench 子集）。无单一模型全面领先。

赢家配方：推理深度胜过广度。

BROWSECOMP

arXiv:2510.06135 · OpenAI · 2025

1,266 个"难找"的网络 query，要求持续导航与创造性搜索。

SOTA：Tongyi-DeepResearch Heavy **69.0%**，显著超过所有公开过分数的闭源 deep-research 系统。OpenAI Deep Research、Tongyi DeepResearch、GLM Deep Research 三家轮替。

赢家配方：带*非对称验证*的 test-time scaling + heavy search planning。

GAIA 已落盘 ADAPTER

arXiv:2311.12983 · 2023

450 个真实世界 QA（3 难度等级、严格 exact match）。最受跟踪的通用基准。

SOTA：GPT-5（high）在 Gaia2 动态基准上 **42% pass@1**（2026）。原 GAIA 排行榜上 OpenAI 与 Anthropic 模型领先；Sibyl、Magnetic-One、Trase、h2oGPTe、Manus 是顶流系统。无模型全维度领先。

本地：113 MB · test 301 题（答案 hidden，用于官方 leaderboard 提交）+ **validation 165 题**（Levels 53/86/26，全部带 Final answer，可本地评分）
`outline/datasets/e2e-general/GAIA/data/2023/{test,validation}/`
Adapter `GAIA/adapter.py`：to-jsonl（按 split + level 切片）/ grade（GAIA 规范化 exact-match）/ stats

赢家配方：工具使用 + 多步推理。

HLE — HUMANITY'S LAST EXAM 已落盘 ADAPTER

arXiv:2501.14249 · 2025

2,500 道专家级跨学科题目，*显式过滤掉*前沿模型能秒答的题。

SOTA： Gemini 3 Pro Preview 官方榜首 **37.5%**，Claude Opus 4.6 Thinking 34.4%，GPT-5 Pro 31.6%（2026 年初）。

本地： 262 MB · 单 parquet（2,500 行 / 8 类目 / 含 342 道图像题） · SHA256 校验通过
`outline/datasets/e2e-general/HLE/data/test-00000-of-00001.parquet`
Adapter `HLE/adapter.py`：to-jsonl / grade（HLE LLM-judge） / stats

赢家配方： 扩展推理 + 代码工具。

SIMPLEQA

arXiv:2411.04368 · OpenAI · 2024

4,326 道短形式事实题（科学、政治、艺术，单一正确答案）。Hallucination 探针。

SOTA： OpenAI Deep Research 与 GPT-4o + browsing 领先；无带具体分数的公开排行榜。

赢家配方： 参数化知识 + 检索增强。

MATH-500 已落盘

HuggingFaceH4/MATH-500 · OpenAI 2024 PRM 训练子集（源自 Hendrycks MATH, NeurIPS '21）

500 道纯数学推理题，按学科（Algebra / Precalculus / Number Theory / Geometry 等） + Level 1–5 平衡。当代*事实标准*的数学推理压力测试。

SOTA：2026-Q1 已基本饱和——GPT-5/o3 95%+，Claude Opus 4.6 Thinking ~94%，Gemini 3 Pro ~93%。如今更多被当作 sanity check 而非前沿榜单。

本地：448 KB · 单 jsonl 500 行 · 学科分布 Algebra 124 / Intermediate Algebra 97 / Prealgebra 82 / Number Theory 62 / Precalculus 56 / Geometry 41 / Counting & Probability 38
`outline/datasets/e2e-general/MATH-500/data/test.jsonl`

赢家配方：扩展推理 + 符号工具。可直接用 hle-answer profile + symbolic-aware grader 跑评。

GPQA-DIAMOND 已落盘 ADAPTER

arXiv:2311.12022 · NYU/Anthropic/Cohere · COLM '24（gated · CC BY 4.0）

198 道*研究生级*多选题，物理 / 化学 / 生物三大领域 PhD 撰写并交叉验证。设计上 Google-proof：领域专家 ~65%，非领域博士 + 半小时浏览只能到 ~34%。OpenAI o-series 与 Anthropic system card 的"硬科学"头条数字。

SOTA：Claude Opus 4.7 ~89.4%（2026-04），Claude Mythos preview ~90.1%（2026-05），GPT-5.4 ~88.1%，o3 ~87.7%，Gemini 2.5 Pro ~86.4%；Open weight：GLM-5.1 ~84.9%、DeepSeek-R2 ~83.6%。前沿压在 ~6 pts 之内，残差很大一部分是 Expert-Validator-Disagreement 的真争议题。

本地：1.34 MB · 单 csv 198 行 × 78 列 · 学科分布 Chemistry 93（其中 Organic 72）/ Physics 86 / Biology 19 · 难度 Hard UG 118 / Hard Grad 61 / Post-Grad 12
`outline/datasets/e2e-general/GPQA-Diamond/data/gpqa_diamond.csv`
Adapter `GPQA-Diamond/adapter.py`：to-jsonl（4 选项 seed-based 打乱 / 多 epoch / 按 domain 分层）/ grade（`Answer: $LETTER` regex 提取，纯 exact match，无需 LLM judge）/ stats

赢家配方：扩展推理 + 领域工具（Physics 端 sympy；Chem 端结构推断）。Adjudication=panel 在 GPQA 上有意义——拿来审 expert-disagreement 题的推理链。

本季度新增（建议收录）

LIVEAGENTBENCH

arXiv:2603.02586 · 2026

104 个真实用户场景（从社交媒体抓取）做 agentic 评测。

SOTA：过新；尚无公开排行榜。

赢家配方：未知。

> *即便在 GAIA 上——450 题、3 个难度——也没有模型全维度领先。HLE 的 37.5% 天花板说明专家级任务远未解决。已饱和（SWE-bench Verified 93.9%）和"开放研究"（PaperBench 21%、HLE 37.5%、AutoResearchBench < 10%）之间的断层，就是 2026 年前沿真正的位置。*
>
> — 2026 年端到端 auto-research 的现状

❧

XI

趋势观察

把所有基准放在一起看，2026 上半年呈现出五条值得记录的曲线。

1. 饱和曲线。SWE-bench Verified 在 6 个月里从 74.9% 一路推到 80.9%，OpenAI 已宣布*不再把它当前沿指标*。SWE-Bench Pro 接班——闭源顶尖 53–64%（Opus 4.7 64.3%），开源 GLM-5.1 58.4%。其他 auto-research 基准跨过 80% 的极少：MLE-bench-30 是唯一跨过 80% 线的（AIRA-2 81.5–83.1%）。PaperBench、RE-Bench、AutoResearchBench 都仍稳稳停在 30–40% 以下。

2. Open vs Closed 差距。在 MMLU 类评测上几乎归零；在 agent 类基准上 ~5–10 分。GLM-5.1（4 月发布）以 ~7% 的成本逼近 Opus 4.6。GPT-OSS 120B、GLM-5.1、DeepSeek V4、Kimi K2.6 是当前四个前沿级 open weight。Tongyi DeepResearch Heavy 在 BrowseComp 上压过闭源——这是本季度最干净的"open 赢了"信号。

3. "Deep research" 已成模型品类。OpenAI 出 `o3-deep-research` 这个独立 SKU；Perplexity、Google（Gemini for Science）、Microsoft（Researcher）、阿里（Tongyi DR）、Z.ai 都有自己挂名"deep research"的产品线。它从一种工作流变成*一类显式区分的模型*。

4. 记忆是瓶颈。Mem0 的 2026 报告把记忆定位成"*有自己专属基准套件的一级架构组件*"。三篇 arXiv 论文（2603.04257 / 2605.03675 / 2602.22769）一致诊断：有限上下文是长程任务的核心瓶颈。一个有用的实操信号——多数所谓"hallucination"其实是 retrieval miss。

5. 成本-能力开始被列入 SOTA。Token 成本现在是显式 SOTA 评分轴。GLM-5.1 报价 $1.00 / $3.20 per million in/out（Opus 4.6: $15 / $75）——7×–23× 的差距和 benchmark 分数一起被并列引用。Tongyi DR 的 MoE（30B 总参 / 3B 激活）讲的是同一个故事：用激活参数的成本换能力。SWE-1.6 同时领先成本（免费）与速度（950 tok/s）。一个编辑标准——*2026 年没有 $/score 列的排行榜表，看起来已经过时*。

> **综合判断**
>
> Auto-research 流水线在 2026 上半年的真实状态是：软件工程 + 数据 QA 的"短任务"端基本饱和；研究类长程任务（>4 小时）仍是难解的；记忆与可靠执行是当前最关键的两个待解块。Open-weight 在 cost-performance 维度首次拿到具体优势；闭源仍在能力天花板上领先。MinionsOS 的"成长"应该集中在长程执行可靠性 + 记忆架构这两条线上。

本报告由 77 个 benchmark meta.json + 7 个并行 SOTA-research agent 于 2026-05-23 汇总，并由额外的 Q1/Q2 调研 agent 补入本季度新材料。所有数字反映 2026-Q1 / Q2 的公开排行榜与系统卡状

态。正文用 Iowan Old Style 衬线（中文回退到 Songti SC / Source Han Serif），导航与表格用 SF Pro Text，代码用 SF Mono。Benchmark 集合存放在 `/Users/mjm/MinionsOS/outline/datasets/`。

修订记录与待入库列表见 `outline/DOWNLOAD_STATUS.md` 与各分级 README。本快照下：原 48 基准已 smoke-test 通过，6 个因 LFS 体积超时未拉，23 个仍为 paper-only 等待资源放出。本季度新增 7 个候选（DRACO、AutoResearchBench、AIRS-Bench、DeepResearch Bench、AgencyBench、PRDBench、LiveAgentBench）建议下一轮入库。

2026-05-23 会话增量：14 个数据集本会话补全或更新（HLE 262 MB / GAIA 113 MB / MATH-500 0.4 MB / GPQA-Diamond 1.3 MB / AutoResearchBench 12 MB / SWE-bench-Pro 95 MB / SWE-EVO 21 MB / AgencyBench 27 MB / PRDBench 79 MB / PaperBench 1.0 GB / IdeaBench 141 MB / IDEA-Bench-ali-vilab 329 MB / LiveIdeaBench 1.1 GB / AI-Idea-Bench-2025 345 MB metadata；总计 ~3.5 GB；AI-Idea-Bench 31 GB 全文 ZIP 按用户要求跳过）。Adapter 已落盘 5 个：`HLE/adapter.py`、`GAIA/adapter.py`、`GPQA-Diamond/adapter.py`、`AutoResearchBench/adapter.py`、`PRDBench/adapter.py`，全部对接 v15 Mission Profile `hle-answer`，可直接 `mos benchmark run <jsonl> --profile hle-answer`。

工程教训写入：`cas-bridge.xethub.hf.co` 实际可达（之前误判 Xet 完全死，仅 hf-mirror.org 域名 NXDOMAIN）；ModelScope CDN 是 gated HF 数据集的稳定 fallback；HF tree API `recursive=true` 在大目录被分页截断到 ~1000 entries，必须按子目录单独枚举；`gh api repos/.../tarball/main` 在 git clone 卡死时立即可用。

编者：MinionsOS · 最后更新：2026-05-23。